

BAB I

PENDAHULUAN

1.1 Latar Belakang

Bagi banyak orang, bergabung dengan pusat kebugaran merupakan langkah awal untuk menuju gaya hidup sehat. Namun, antusiasme awal tersebut sering kali berhadapan dengan kenyataan yang membingungkan. Anggota baru, terutama pemula, kerap dihadapkan pada berbagai jenis peralatan dan variasi program latihan tanpa pemahaman yang jelas mengenai metode yang paling sesuai dengan kondisi fisik dan tujuan pribadi mereka. Kurangnya panduan yang terpersonalisasi ini menyebabkan banyak pengguna khususnya yang tidak didampingi pelatih pribadi melakukan latihan secara acak, sehingga berisiko mengalami cedera atau gagal mencapai target yang diinginkan. Akibatnya, tingkat keanggotaan yang berhenti di *gym* cukup tinggi karena banyak peserta merasa tidak memperoleh hasil yang diharapkan setelah beberapa bulan [1].

Kondisi tersebut merepresentasikan situasi aktual di Max Gym Power Padang. Anggota pemula di pusat kebugaran ini didominasi oleh kalangan mahasiswa dengan tingkat retensi keanggotaan rata-rata pada rentang tiga hingga lima bulan. Meskipun sebagian anggota telah konsisten berlatih, target kebugaran sering kali tidak tercapai akibat pola makan yang tidak selaras dengan program latihan mereka. Pihak pengelola *gym* menyediakan instruktur untuk latihan, namun keterbatasan anggaran membuat anggota pemula cenderung menghindari opsi penyewaan instruktur pribadi dan jarang yang memiliki layanan pendampingan nutrisi yang dapat memberikan panduan nutrisi secara personal. Konsekuensinya, anggota mengandalkan asumsi pribadi mengatur asupan nutrisi mereka, yang berpotensi menjadikan program kebugaran mereka tidak seimbang dan kurang efektif [1], [2]. Padahal, strategi nutrisi yang presisi, khususnya asupan protein yang memadai, terbukti secara ilmiah merupakan elemen krusial untuk mendukung adaptasi otot dan pemulihan pasca latihan fisik [3].

Kondisi ini menunjukkan adanya kebutuhan yang nyata akan sistem yang mampu memberikan rekomendasi personal secara otomatis dan akurat. Sistem rekomendasi merupakan salah satu solusi teknologi yang telah banyak diimplementasikan untuk membantu pengguna dalam membuat keputusan dari sekumpulan pilihan yang besar. Dalam konteks kesehatan, sistem rekomendasi telah diterapkan untuk berbagai keperluan mulai dari rekomendasi obat, jadwal olahraga, hingga perencanaan diet. Sharma et al. (2023) dalam kajian komprehensifnya menyatakan bahwa sistem rekomendasi berbasis machine learning dalam domain kesehatan telah berkembang jauh dari pendekatan berbasis aturan sederhana menuju arsitektur yang mampu beradaptasi dengan kebutuhan individual pengguna secara dinamis [4]. Pendekatan umum yang digunakan dalam sistem rekomendasi mencakup *collaborative filtering*, *content-based filtering* (CBF), dan metode *hybrid* yang menggabungkan keduanya. Namun, masing-masing pendekatan ini memiliki keterbatasan tersendiri, seperti masalah *cold-start* pada collaborative filtering [5] dan kurangnya keberagaman rekomendasi pada CBF yang berdiri sendiri, sehingga metode *hybrid* menjadi solusi yang lebih unggul [6].

Tantangan lebih lanjut dalam membangun sistem rekomendasi di domain kebugaran dan kesehatan adalah Kebutuhan akan panduan personal ini memerlukan pengembangan otomatisasi sistem rekomendasi dengan kapabilitas pemrosesan data kebugaran yang beraneka ragam. Basis data sistem ini mencakup tiga entitas utama dengan karakteristik struktur yang berbeda: profil pengguna, komposisi gizi makanan, dan spesifikasi latihan. Profil pengguna merupakan data campuran (*mixed data*) yang menggabungkan atribut numerik (usia, berat badan, tinggi badan) dan kategorikal (tujuan kebugaran, tingkat aktivitas). Penanganan tipe campuran ini menuntut algoritma klasterisasi khusus karena algoritma konvensional tidak mendistribusikan pengukuran jarak (*distance metric*) secara proporsional [7]. Berbeda dengan profil pengguna, data menu makanan memiliki struktur murni numerik (kandungan kalori, protein, lemak), sedangkan data program latihan tersusun atas atribut kategorikal (target otot, peralatan). Algoritma K-Prototypes, yang merupakan pengembangan dari K-Means, dirancang khusus untuk menangani data bertipe campuran dengan menggabungkan jarak Euclidean

untuk atribut numerik dan jarak Hamming untuk atribut kategorikal [7]. Penerapan K-Prototypes dalam berbagai domain telah menunjukkan hasil yang superior dibandingkan K-Means, di antaranya dalam segmentasi pelanggan ritel [8], sistem rekomendasi berbasis data besar [9], dan pengelompokan pengguna dalam domain *ambient assisted living* [10].

Penelitian ini mengusulkan arsitektur sistem rekomendasi *hybrid* yang memadukan model klasterisasi spesifik untuk masing-masing tipe entitas data. Algoritma K-Prototypes diterapkan untuk pengelompokan profil anggota, K-Means untuk segmentasi klaster menu makanan, dan K-Modes untuk kategorisasi program latihan. Titik pusat klaster (*centroid* dan *mode*) dari ketiga algoritma tersebut diintegrasikan menggunakan metode *Content-Based Filtering* (CBF) untuk menghasilkan luaran rekomendasi yang presisi. Konstruksi sistem dibangun menggunakan bahasa pemrograman Python atas pertimbangan ketersediaan ekosistem pustaka komputasi matriks dan pemodelan algoritma. Antarmuka purwarupa dikembangkan melalui *framework* Streamlit guna mengakomodasi rendering objek data interaktif dari model *machine learning* ke antarmuka pengguna tanpa memerlukan pemisahan infrastruktur *backend* dan *frontend*.

Guna merealisasikan seluruh gagasan tersebut menjadi sebuah sistem perangkat lunak yang tidak hanya fungsional tetapi juga teruji keandalannya, serta sebagai upaya strategis untuk menjawab kebutuhan personalisasi layanan bagi anggota di pusat kebugaran, maka penelitian ini disusun dalam bentuk Tugas Akhir dengan judul “Sistem Rekomendasi *Hybrid* Menu Makanan dan Latihan Berbasis K-Prototypes dan *Content-Based Filtering* di Max Power Gym Padang”.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, ketiadaan panduan gizi dan latihan fisik yang terstruktur bagi anggota pemula di Max Gym Power Padang menyebabkan tidak tercapainya target kebugaran yang berujung pada berhentinya keanggotaan. Keterbatasan biaya mahasiswa untuk menyewa instruktur pribadi, ditambah dengan ketiadaan rekomendasi diet dari instruktur, menuntut adanya otomatisasi panduan. Namun, pencocokan profil pengguna dengan panduan latihan dan makanan menjadi rumit karena kompleksitas perbedaan tipe data pada profil pengguna (campuran), data makanan (numerik), dan data latihan (kategorikal).

Berdasarkan kondisi tersebut, permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana merancang arsitektur sistem rekomendasi *hybrid* yang mampu mengelola dan memetakan tiga entitas data yang berbeda secara terintegrasi di Max Gym Power Padang?
2. Bagaimana menerapkan algoritma K-Prototypes untuk mengelompokkan profil anggota *gym* (campuran), K-Means untuk mengelompokkan data menu makanan (numerik), dan K-Modes untuk mengelompokkan data latihan (kategorikal)?
3. Bagaimana mengintegrasikan hasil klasterisasi dari ketiga model algoritma tersebut dengan metode *Content-Based Filtering* untuk menghasilkan rekomendasi gizi dan kebugaran yang relevan bagi setiap anggota?
4. Bagaimana memvalidasi tingkat akurasi sistem rekomendasi *hybrid* K-Prototypes dan *Content-Based Filtering* dalam menghasilkan rekomendasi yang sesuai dengan preferensi dan kebutuhan nyata anggota Max Gym Power Padang?

1.3 Tujuan

Penelitian proyek akhir ini mengajukan suatu pendekatan yang baru untuk mengatasi permasalahan rekomendasi gizi dan kebugaran dengan mempresentasikan sistem *hybrid* yang menggabungkan klasterisasi K-Prototypes dan Content-Based Filtering:

1. Merancang dan membangun arsitektur sistem rekomendasi *hybrid* yang mampu memproses berbagai tipe karakteristik data dalam domain kebugaran secara bersamaan.
2. Menerapkan algoritma K-Prototypes untuk memproses data profil campuran (*mixed data*) anggota *gym*, K-Means untuk segmentasi nilai gizi makanan, dan K-Modes untuk kategorisasi jenis latihan.
3. Mengintegrasikan hasil klasterisasi dengan metode *Content-Based Filtering* untuk menghasilkan rekomendasi menu makanan dan program latihan *gym* yang personal dan relevan sesuai dengan profil spesifik setiap anggota.

4. Memvalidasi tingkat akurasi sistem rekomendasi *hybrid* K-Prototypes dan *Content-Based Filtering* dalam menghasilkan rekomendasi yang sesuai dengan preferensi dan kebutuhan nyata anggota Max Gym Power Padang.

1.4 Manfaat

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi Anggota Max Gym Power Padang: Sistem rekomendasi *hybrid* dapat memberikan panduan personal terkait menu makanan dan program latihan yang sesuai dengan profil fisik, tujuan kebugaran, preferensi diet, serta kondisi kesehatan masing-masing anggota, sehingga membantu anggota khususnya pemula dalam menjalani program kebugaran yang lebih terarah, aman, dan efektif.
2. Bagi Pengelola Max Gym Power Padang: Sistem ini dapat menjadi nilai tambah layanan yang membedakan Max Gym Power Padang dari pusat kebugaran lainnya, karena mampu menghadirkan pengalaman yang lebih personal bagi setiap anggota tanpa harus menambah jumlah tenaga instruktur, sehingga berpotensi meningkatkan kepuasan, loyalitas, dan tingkat retensi keanggotaan.
3. Bagi Akademisi dan Peneliti: Penelitian ini memberikan kontribusi akademik berupa penerapan algoritma K-Prototypes untuk klasterisasi data bertipe campuran dalam domain kebugaran dan kesehatan, yang selama ini masih terbatas dalam literatur, serta dapat menjadi referensi bagi penelitian selanjutnya dalam pengembangan sistem rekomendasi kesehatan yang lebih komprehensif.
4. Bagi Pengembang Sistem: Penelitian ini memberikan gambaran teknis yang terperinci mengenai penerapan algoritma K-Prototypes dan integrasinya dengan metode *Content-Based Filtering* dalam satu arsitektur *hybrid*, yang dapat dijadikan acuan dalam pengembangan sistem personalisasi berbasis data campuran di berbagai domain aplikasi lainnya.

1.5 Batasan Masalah

Untuk memperjelas ruang lingkup penelitian dan memastikan fokus yang terarah, penelitian ini dibatasi pada hal-hal berikut:

1. Sistem difokuskan pada konteks gym, dengan dua aspek utama yaitu menu makanan dan jenis latihan.
2. Sistem tidak mencakup aspek kesehatan lain seperti kondisi medis tertentu atau kondisi fisik khusus.
3. Klasterisasi pengguna menggunakan algoritma K-Prototypes berdasarkan data profil seperti jenis kelamin, usia, Berat Badan, Tinggi Badan, tingkat aktivitas, tingkat pengalaman, dan tujuan kebugaran.
4. Klasterisasi item pada data menu makanan menggunakan algoritma K-Means.
5. Klasterisasi item pada data latihan menggunakan algoritma K-Modes.
6. Metode rekomendasi dilakukan dengan pendekatan Content-Based Filtering (CBF) untuk menghasilkan rekomendasi personal yang relevan dengan kategori item hasil klasterisasi.
7. Dataset makanan hanya mencakup makanan yang umum tersedia di Indonesia
8. Dataset latihan difokuskan pada latihan umum yang dapat dilakukan dengan peralatan standar gym.
9. Pengguna yang menjadi sasaran penelitian ini adalah anggota gym/fitness pemula hingga menengah yang membutuhkan sistem rekomendasi sebagai pendamping latihan dan pola makan.
10. Sistem hanya bersifat sebagai alat bantu rekomendasi, bukan pengganti dokter, ahli gizi, atau pelatih pribadi.
11. Basis data menggunakan PostgreSQL sebagai sistem manajemen basis data.
12. Sistem dibangun berbasis web menggunakan Python dan Streamlit, dengan fokus pada fungsionalitas rekomendasi, bukan pada aspek desain grafis tingkat lanjut.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Penelitian terkait memuat hasil penelitian pihak lain yang mempunyai *Problem* yang sama dengan penelitian ini, yaitu ketiadaan panduan gizi dan latihan yang terpersonalisasi bagi anggota gym, namun dengan *Uniqueness* yang berbeda-beda. Kajian berikut disusun dari cakupan riset yang paling umum (teori dan tren sistem rekomendasi secara luas), menyempit ke validasi metodologis lintas domain, hingga yang paling dekat dengan konteks kesehatan dan kebugaran, guna memperkuat klaim orisinalitas sekaligus mengidentifikasi celah (*gap*) yang belum terisi dalam literatur.

Pada tataran paling umum, Sharma et al. mengulas secara komprehensif evolusi sistem rekomendasi berbasis *machine learning* di domain kesehatan, dari pendekatan berbasis aturan sederhana menuju arsitektur yang adaptif terhadap kebutuhan individual, sekaligus menegaskan bahwa pendekatan *hybrid* unggul dibandingkan metode tunggal karena mampu saling menutupi kelemahan *collaborative filtering* dan *content-based filtering* [4]. Sejalan dengan itu, Kirk et al. dalam tinjauan penerapan *machine learning* pada riset nutrisi menunjukkan bahwa algoritma klasterisasi keluarga K-Means termasuk adaptasinya untuk data kategorikal (K-Modes) dan data campuran (K-Prototypes) telah menjadi pendekatan dominan untuk mensegmentasi data pangan dan profil individu, yang kemudian dipadukan dengan metode rekomendasi berbasis konten maupun popularitas [18]. Kedua kajian ini menjadi landasan bahwa arah *hybrid* clustering CBF yang diusulkan pada penelitian ini sejalan dengan tren riset terkini, namun keduanya masih bersifat tinjauan umum tanpa implementasi sistem yang konkret.

Pada tataran validasi metodologis, sejumlah penelitian membuktikan keunggulan algoritma K-Prototypes dalam menangani data bertipe campuran di berbagai domain aplikasi yang tidak berkaitan langsung dengan kesehatan. Aschenbruck memperluas cakupan algoritma K-Prototypes untuk menangani lebih banyak skenario data campuran dan menyimpulkan algoritma ini memiliki

fleksibilitas tinggi untuk diimplementasikan lintas domain [7]. Chok et al. menerapkan K-Prototypes untuk mengidentifikasi lima segmen konten pada platform Netflix berdasarkan atribut format, durasi, dan kategori, dan menyimpulkan metode ini lebih tepat dibandingkan K-Means ketika data memuat atribut kategorikal [14]. Temuan serupa dilaporkan Kumar, yang memadukan K-Prototypes dengan *XGBoost* untuk klasterisasi profil pengguna campuran dalam sistem rekomendasi jalur karier, dan membuktikan efektivitas K-Prototypes dibandingkan K-Means pada data heterogen [13]. Kumpulan penelitian ini secara konsisten membuktikan superioritas K-Prototypes atas K-Means pada data campuran di berbagai domain, tetapi tak satu pun mengangkat konteks kebugaran atau menggabungkannya dengan K-Means dan K-Modes sekaligus dalam satu arsitektur.

Pada tataran yang paling dekat dengan penelitian ini, yaitu kesehatan dan layanan personal berbasis profil pengguna, Stavrotheodoros et al. menerapkan pendekatan *matchmaking hybrid* berbasis K-Prototypes pada domain *ambient assisted living* dan menyimpulkan algoritma ini tepat digunakan ketika profil pengguna memuat atribut campuran yang tidak dapat diproses K-Means saja sebuah karakteristik data yang serupa dengan profil anggota gym pada penelitian ini [10]. Abedini et al. menunjukkan bahwa pemanfaatan informasi demografis pengguna, termasuk atribut kategorikal, secara eksplisit meningkatkan kemampuan sistem rekomendasi mengatasi masalah *cold-start* bagi pengguna baru [5], sebuah prinsip yang relevan dengan skema *nearest prototype assignment* pada sistem ini. Yang paling dekat secara domain, Valles-Coral et al. mengembangkan sistem pakar *hybrid* yang memadukan *content-based filtering* dengan jaringan saraf tiruan untuk menghasilkan rekomendasi gaya hidup personal bagi pasien hipertensi, dan menyimpulkan pendekatan *hybrid* lebih unggul dibandingkan metode tunggal namun secara eksplisit belum mengimplementasikan pendekatan klasterisasi tipe campuran seperti K-Prototypes secara penuh dalam arsitekturnya [11].

Berdasarkan kajian di atas, dapat diidentifikasi bahwa penelitian-penelitian terdahulu telah membuktikan keunggulan K-Prototypes dalam menangani data campuran di berbagai domain [7], [10], [13]–[15], efektivitas informasi demografis/kategorikal dalam mengatasi *cold-start* [5], serta keunggulan

pendekatan *hybrid* dibandingkan metode tunggal pada konteks kesehatan [4], [11], [18]. Namun, belum ditemukan penelitian yang secara spesifik mengintegrasikan tiga algoritma klasterisasi berbeda K-Prototypes untuk profil pengguna campuran, K-Means untuk data numerik menu makanan, dan K-Modes untuk data kategorikal program latihan, secara simultan dalam satu arsitektur sistem rekomendasi *hybrid* berbasis *Content-Based Filtering* untuk domain kebugaran. Penelitian ini mengisi celah tersebut dengan membangun sistem yang memetakan tiga entitas data berbeda secara terintegrasi, menggunakan algoritma yang sesuai dengan karakteristik masing-masing tipe data.

2.2 Teori Penunjang

2.2.1. Sistem Rekomendasi

Sistem rekomendasi (*recommender system*) adalah suatu sistem perangkat lunak yang dirancang untuk memprediksi preferensi atau kebutuhan pengguna terhadap suatu item dan menyajikan item-item yang paling relevan secara otomatis [4]. Sistem ini bekerja dengan memproses data historis pengguna, atribut item, maupun kombinasi keduanya untuk menghasilkan daftar rekomendasi yang dipersonalisasi. Dalam konteks kebugaran dan kesehatan, sistem rekomendasi telah diterapkan untuk berbagai keperluan mulai dari rekomendasi jadwal olahraga, perencanaan diet, hingga rekomendasi program latihan yang disesuaikan dengan kondisi fisik pengguna [4].

Secara umum, sistem rekomendasi dibagi menjadi tiga pendekatan utama. Pertama, *collaborative filtering* (CF) yang menghasilkan rekomendasi berdasarkan kesamaan perilaku atau preferensi antar pengguna, namun memiliki kelemahan mendasar berupa masalah *cold-start* ketika data historis pengguna baru belum tersedia [5]. Kedua, *content-based filtering* (CBF) yang menghasilkan rekomendasi berdasarkan kemiripan atribut item dengan profil pengguna, sehingga tidak bergantung pada data pengguna lain namun cenderung menghasilkan rekomendasi yang kurang beragam. Ketiga, metode *hybrid* yang menggabungkan dua atau lebih pendekatan untuk menutupi kelemahan masing-masing dan menghasilkan rekomendasi yang lebih akurat dan beragam [6]. Penelitian ini mengadopsi pendekatan *hybrid* yang memadukan klasterisasi berbasis algoritma dengan metode CBF berbasis TF-IDF dan kesamaan kosinus.

Kelebihan utama sistem rekomendasi *hybrid* adalah kemampuannya memproses berbagai tipe data sekaligus dan menghasilkan rekomendasi yang lebih robust terhadap keterbatasan data, serta dapat mengatasi masalah *cold-start* karena bergantung pada atribut item dan profil pengguna yang eksplisit. Kekurangannya terletak pada kompleksitas arsitektur yang lebih tinggi serta kebutuhan komputasi yang lebih besar dibandingkan metode tunggal [11].

2.2.2. *Content-Based Filtering* (CBF) dengan TF-IDF dan Kesamaan Kosinus

Content-Based Filtering (CBF) adalah metode rekomendasi yang bekerja dengan cara mencocokkan atribut atau fitur dari item yang tersedia dengan profil preferensi pengguna [6]. Berbeda dengan *collaborative filtering* yang mengandalkan interaksi antar pengguna, CBF sepenuhnya bergantung pada representasi konten item itu sendiri. Dalam penelitian ini, CBF menggunakan pendekatan dua tahap: (1) konversi teks deskriptif menjadi representasi numerik menggunakan TF-IDF, dan (2) pengukuran kesamaan antara profil pengguna dan atribut item menggunakan kesamaan kosinus.

TF-IDF (Term Frequency - Inverse Document Frequency) adalah algoritma pembobotan kata yang mengevaluasi seberapa penting sebuah kata dalam suatu dokumen relatif terhadap seluruh kumpulan dokumen. TF-IDF terdiri dari dua komponen: *Term Frequency* (TF) yang mengukur frekuensi kata dalam dokumen tertentu, dan *Inverse Document Frequency* (IDF) yang memberikan bobot lebih tinggi pada kata-kata jarang muncul karena dianggap lebih informatif. Rumus TF-IDF untuk kata t dalam dokumen d dalam kumpulan dokumen D adalah:

$$TF - IDF(t, d) = TF(t, d) \times IDF(t, D) \quad (2.1)$$

Dimana:

$$TF(t, d) = \frac{\text{jumlah kemunculan } t \text{ di } d}{\text{total kata di } d} \quad (2.2)$$

$$IDF(t, D) = \log \left(\frac{\text{jumlah dokumen di } D}{\text{jumlah dokumen yang mengandung } t} \right) \quad (2.3)$$

Dalam konteks penelitian ini, setiap menu makanan dan program latihan merupakan "dokumen", dan deskripsi item (nama, jenis bahan, target otot, dll) diubah menjadi vektor TF-IDF. Dengan cara ini, kata-kata yang sangat spesifik seperti "barbell" atau "dada" mendapat bobot tinggi, sementara kata-kata umum seperti "dengan" atau "untuk" diabaikan. Hal ini memastikan bahwa pencocokan item didasarkan pada fitur-fitur yang paling diskriminatif.

Kesamaan Kosinus (Cosine Similarity) Setelah setiap item dan preferensi pengguna direpresentasikan sebagai vektor TF-IDF, tingkat kesamaan di antara keduanya diukur menggunakan kesamaan kosinus, yaitu kosinus dari sudut di antara dua vektor dalam ruang dimensi tinggi. Rumus kesamaan kosinus antara vektor pengguna u dan vektor item i adalah:

$$\text{cosine similarity}(u, i) = \frac{u \cdot i}{|u| \times |i|} \quad (2.4)$$

Di mana $u \cdot i$ adalah hasil perkalian titik (*dot product*) kedua vektor, dan $|u|$ serta $|i|$ adalah magnitudo (panjang) masing-masing vektor. Nilai kesamaan kosinus berkisar antara 0 hingga 1, di mana nilai mendekati 1 menunjukkan kemiripan yang sangat tinggi, dan nilai mendekati 0 menunjukkan kemiripan yang sangat rendah atau tidak ada.

Dalam praktik implementasi sistem ini, setiap kali pengguna masuk melalui sistem, preferensi mereka (tujuan kebugaran) dikonversi menjadi vektor TF-IDF, lalu dicocokkan dengan vektor setiap item makanan atau latihan dalam database menggunakan cosine similarity. Item-item dengan nilai cosine similarity tertinggi dipilih sebagai kandidat rekomendasi. Untuk meningkatkan keberagaman rekomendasi, sistem juga mempertimbangkan kluster asal item (hasil K-Means atau K-Modes) agar rekomendasi tidak monoton dari satu kategori saja.

Kelebihan CBF berbasis TF-IDF dan cosine similarity adalah transparansi (mudah dijelaskan mengapa suatu item direkomendasikan), tidak memerlukan data dari pengguna lain, dan dapat mengatasi masalah *cold-start* untuk pengguna dan item baru. Kekurangannya adalah kecenderungan menghasilkan rekomendasi

yang monoton (*over-specialization*) jika tidak diintegrasikan dengan mekanisme diversifikasi, serta ketergantungan pada kualitas deskripsi item [6]. Dalam penelitian ini, integrasi dengan klaster hasil K-Means dan K-Modes berfungsi sebagai mekanisme diversifikasi untuk mengatasi kelemahan ini.

2.2.3. Algoritma K-Prototypes

K-Prototypes adalah algoritma klasterisasi yang dikembangkan khusus untuk menangani data bertipe campuran (*mixed-type data*), yaitu data yang mengandung atribut numerik dan kategorikal secara bersamaan [7]. Algoritma ini merupakan perpaduan dari K-Means yang digunakan untuk atribut numerik dan K-Modes yang digunakan untuk atribut kategorikal. Kebutuhan akan algoritma ini muncul karena K-Means tidak dapat mengukur jarak pada atribut kategorikal secara proporsional, sehingga penerapannya pada data campuran menghasilkan klaster yang bias dan tidak representatif.

Dalam penelitian ini, K-Prototypes diterapkan pada fase *preprocessing offline* menggunakan dataset sintetis (*synthetic dataset*) yang dibangkitkan secara komputasional untuk menghasilkan k prototipe klaster awal. Pendekatan ini dipilih karena sistem belum memiliki data pengguna nyata pada saat pertama kali dioperasikan (*cold-start problem*), sehingga model K-Prototypes perlu dilatih terlebih dahulu di luar sesi pengguna menggunakan data dummy yang secara logis merepresentasikan variasi demografi kebugaran. Setiap prototipe merepresentasikan profil pengguna tipikal dari satu kelompok anggota. Pada saat pengguna baru mendaftar melalui sistem, sistem tidak menjalankan K-Prototypes dari nol, melainkan menghitung jarak profil pengguna baru ke setiap prototipe yang sudah tersimpan, lalu menetapkan pengguna ke klaster dengan prototipe terdekat. Pendekatan ini disebut *nearest prototype assignment* dan memastikan pengguna baru langsung terkategori tanpa mengganggu struktur klaster yang sudah stabil maupun tanpa memerlukan data historis [19].

Fungsi jarak yang digunakan oleh K-Prototypes merupakan kombinasi jarak Euclidean untuk atribut numerik dan jarak Hamming untuk atribut kategorikal:

$$d(x, p) = \sum_{j=1}^n (x_j^{\text{num}} - p_j^{\text{num}})^2 + \gamma \sum_{j=1}^m \delta(x_j^{\text{cat}}, p_j^{\text{cat}}) \quad (2.5)$$

di mana x adalah titik data (profil pengguna), p adalah prototipe kluster, n adalah jumlah atribut numerik (usia, berat badan, dan tinggi badan), m adalah jumlah atribut kategorikal (jenis kelamin, tingkat aktivitas, tingkat pengalaman, dan tujuan kebugaran), γ adalah parameter pembobot yang menyeimbangkan kontribusi kedua tipe atribut, dan δ adalah fungsi Hamming yang bernilai 0 jika dua nilai kategorikal sama dan 1 jika berbeda.

Proses kerja K-Prototypes pada fase preprocessing terdiri dari empat tahap iteratif: (1) inisialisasi sejumlah k prototipe awal secara acak dari data; (2) penetapan setiap titik data ke kluster dengan prototipe terdekat berdasarkan fungsi jarak; (3) pembaruan prototipe dengan menghitung rata-rata (*mean*) untuk atribut numerik dan nilai *mode* (nilai paling sering muncul) untuk atribut kategorikal; (4) pengulangan tahap 2 dan 3 hingga posisi prototipe tidak berubah signifikan (konvergen).

Kelebihan K-Prototypes adalah kemampuannya memproses data campuran tanpa transformasi atau *encoding* yang dapat menyebabkan distorsi makna data [7]. Kekurangannya adalah sensitivitas terhadap nilai k dan γ yang secara teoretis harus ditentukan secara manual, serta rentan terhadap pengaruh *outlier* dan inisialisasi yang buruk. Dalam implementasi penelitian ini, kelemahan penentuan γ secara manual dimitigasi dengan memanfaatkan kalkulasi otomatis pada *library* *kmodes*, yang menghitung γ sebagai setengah dari rata-rata varians kolom numerik menggunakan metode inisialisasi Cao, sehingga parameter ini tidak perlu ditentukan secara manual oleh peneliti. Dalam penelitian ini, K-Prototypes diterapkan khusus untuk mengelompokkan profil anggota gym yang memiliki atribut campuran, yaitu usia, berat badan, tinggi badan (numerik) serta jenis kelamin, tingkat aktivitas, tingkat pengalaman, dan tujuan kebugaran (kategorikal).

2.2.4. Algoritma K-Means

K-Means adalah algoritma klasterisasi berbasis partisi yang paling banyak digunakan untuk mengelompokkan data bertipe numerik [9]. Algoritma ini bekerja dengan cara membagi sekumpulan n titik data ke dalam k klaster sedemikian rupa sehingga setiap titik data berada dalam klaster dengan *centroid* (pusat klaster) terdekat. *Centroid* adalah titik pusat klaster yang dihitung sebagai rata-rata (*mean*) dari seluruh titik data yang menjadi anggota klaster tersebut.

Dalam penelitian ini, K-Means diterapkan pada fase *preprocessing offline* menggunakan dataset menu makanan lokal untuk mengelompokkan makanan berdasarkan komposisi gizi (kalori, protein, lemak, karbohidrat). Hasil klasterisasi menghasilkan k *centroid* makanan yang merepresentasikan profil nutrisi tipikal dari setiap klaster, misalnya klaster yang didominasi karbohidrat, klaster yang didominasi protein dan lemak, serta klaster dengan kalori rendah. Karakteristik klaster inilah yang kemudian dijadikan acuan oleh *rule-based engine* dalam menyusun template komposisi menu wajib untuk setiap slot waktu makan (*Slot-Based Meal Templating*), sehingga keberagaman hasil rekomendasi tidak ditentukan oleh perbedaan waktu makan secara langsung, melainkan oleh aturan komposisi klaster yang wajib dipenuhi CBF pada setiap slot. Mekanisme ini dijelaskan lebih rinci pada Bab III sub-bab *Rule-Based Engine*.

Fungsi objektif yang diminimalkan oleh K-Means adalah jumlah kuadrat jarak (*Sum of Squared Errors* / SSE) antara setiap titik data dengan *centroid* klasternya:

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (2.6)$$

di mana k adalah jumlah klaster, C_i adalah himpunan titik data pada klaster ke- i , x adalah titik data, dan μ_i adalah *centroid* klaster ke- i .

Proses kerja K-Means pada fase preprocessing terdiri dari empat tahap iteratif: (1) pemilihan k *centroid* awal secara acak dari data; (2) penetapan setiap titik data ke klaster dengan *centroid* terdekat berdasarkan jarak Euclidean; (3) pembaruan *centroid* setiap klaster dengan menghitung rata-rata seluruh titik data

anggotanya; (4) pengulangan tahap 2 dan 3 hingga posisi *centroid* tidak berubah secara signifikan (konvergen).

Kelebihan K-Means adalah kesederhanaan implementasi, efisiensi komputasi pada dataset besar (seperti dataset makanan dengan ratusan item), dan hasil yang mudah diinterpretasikan melalui nilai *centroid* [9]. Kekurangannya adalah ketidakmampuannya menangani atribut kategorikal, sensitivitas terhadap *outlier* (misalnya makanan ekstrem tinggi kalori atau protein), dan ketergantungan pada nilai k yang harus ditentukan sebelumnya. Dalam penelitian ini, K-Means digunakan khusus untuk mengelompokkan data menu makanan lokal yang seluruh atributnya bersifat numerik (kandungan kalori, protein, lemak, dan karbohidrat).

2.2.5. Algoritma K-Modes

K-Modes adalah algoritma klusterisasi yang merupakan adaptasi dari K-Means untuk menangani data yang seluruh atributnya bersifat kategorikal [16]. Algoritma ini menggantikan konsep *mean* dengan *mode* (nilai yang paling sering muncul dalam suatu kluster) sebagai representasi pusat kluster, serta menggantikan jarak Euclidean dengan jarak Hamming sebagai metrik kesamaan antar titik data.

Dalam penelitian ini, K-Modes diterapkan pada fase *preprocessing offline* menggunakan dataset program latihan gym untuk mengelompokkan latihan berdasarkan atribut kategorikal (*Title*, *BodyPart*, *Equipment*, *Type*). Hasil klusterisasi menghasilkan *kmode* (profil latihan tipikal) dari setiap kluster. Karena seluruh atribut input K-Modes bersifat kategorikal, algoritma ini tidak memerlukan parameter pembobot γ yang digunakan pada K-Prototypes untuk menyeimbangkan kontribusi atribut numerik dan kategorikal. Pada saat sistem menghasilkan rekomendasi latihan melalui CBF, sistem mempertimbangkan kluster asal setiap latihan berdasarkan kesamaan *Equipment* untuk diversifikasi, memastikan setiap sesi rekomendasi latihan mencakup variasi jenis peralatan (misalnya kombinasi Barbell, Dumbbell, dan Cable/Machine) dan tidak didominasi satu kluster peralatan yang sama. Mekanisme ini diimplementasikan sebagai *Cluster Diversity Enforcer* yang dijelaskan lebih rinci pada Bab III.

Fungsi jarak yang digunakan dalam K-Modes adalah jarak *simple matching dissimilarity*:

$$d(x, y) = \sum_{j=1}^m \delta(x_j, y_j) \quad (2.7)$$

di mana m adalah jumlah atribut kategorikal, dan $\delta(x_j, y_j)$ bernilai 0 jika $x_j = y_j$ (nilai atribut ke- j sama) dan bernilai 1 jika $x_j \neq y_j$ (nilai berbeda).

Proses kerja K-Modes pada fase preprocessing terdiri dari empat tahap iteratif: (1) inisialisasi *kmode* awal secara acak dari data; (2) penetapan setiap titik data ke klaster dengan *mode* paling mirip berdasarkan jarak Hamming; (3) pembaruan *mode* klaster dengan memilih nilai yang paling sering muncul pada setiap atribut dari seluruh anggota klaster; (4) pengulangan tahap 2 dan 3 hingga posisi *mode* konvergen. Fungsi objektif yang diminimalkan adalah total jarak *matching* antara seluruh titik data dengan *mode* klasternya.

Kelebihan K-Modes adalah kemampuannya memproses data kategorikal secara langsung tanpa transformasi numerik yang dapat mengubah makna semantik, serta hasil klaster yang mudah diinterpretasikan dalam bahasa domain (misalnya: klaster latihan "upper body dengan dumbbell" atau "lower body dengan barbell") [16]. Kekurangannya adalah sama dengan K-Means, yaitu memerlukan penentuan nilai *k* terlebih dahulu, rentan terhadap inisialisasi yang buruk, dan dapat menghasilkan klaster dengan ukuran yang sangat tidak seimbang. Dalam penelitian ini, K-Modes digunakan untuk mengelompokkan data program latihan gym yang seluruh atributnya bersifat kategorikal.

2.2.6. Indeks Massa Tubuh (IMT)

Indeks Massa Tubuh (IMT) atau *Body Mass Index* (BMI) adalah ukuran yang digunakan secara luas untuk menilai komposisi tubuh seseorang berdasarkan perbandingan antara berat badan dan kuadrat tinggi badan. IMT digunakan sebagai indikator awal status gizi dan risiko kesehatan terkait berat badan, meskipun tidak mengukur persentase lemak tubuh secara langsung. Dalam konteks kebugaran, IMT menjadi salah satu parameter kunci dalam menentukan program latihan dan target kalori yang sesuai bagi setiap individu.

Rumus perhitungan IMT dinyatakan sebagai berikut:

$$IMT = \frac{BB}{TB^2} \quad (2.8)$$

di mana BB adalah berat badan dalam satuan kilogram (kg) dan TB adalah tinggi badan dalam satuan meter (m).

Klasifikasi status gizi berdasarkan nilai IMT menurut standar WHO Asia-Pasifik yang diadopsi oleh Kementerian Kesehatan Indonesia adalah sebagai berikut:

Tabel 2. 1 Klasifikasi IMT menurut WHO Asia-Pasifik

Kategori	Rentang IMT (kg/m ²)
Kurus (Underweight)	< 18,5
Normal	18,5 – 22,9
Gemuk (Overweight)	23,0 – 24,9
Obesitas Kelas I	25,0 – 29,9
Obesitas Kelas II	≥ 30,0

Dalam penelitian ini, nilai IMT digunakan sebagai salah satu atribut numerik pada algoritma K-Prototypes untuk mengelompokkan profil anggota gym. Kluster yang terbentuk berdasarkan IMT bersama atribut lainnya (usia, jenis kelamin, tingkat aktivitas) digunakan sebagai dasar penyesuaian rekomendasi menu makanan dan program latihan agar sesuai dengan kondisi fisik aktual setiap anggota.

2.2.7. Kebutuhan Kalori dan Protein

Kalori adalah satuan energi yang digunakan untuk mengukur jumlah energi yang terkandung dalam makanan dan jumlah energi yang dibutuhkan tubuh untuk menjalankan fungsi fisiologisnya [*referensi ditambahkan sendiri*]. Kebutuhan kalori harian setiap individu bersifat unik dan dipengaruhi oleh berbagai faktor, di antaranya usia, jenis kelamin, berat badan, tinggi badan, dan tingkat aktivitas fisik.

Metode yang digunakan dalam penelitian ini untuk mengestimasi kebutuhan kalori harian adalah persamaan Mifflin-St Jeor, yang dianggap lebih akurat dibandingkan persamaan Harris-Benedict klasik, terutama untuk populasi modern dengan variasi tingkat aktivitas yang beragam. Mifflin-St Jeor menghitung terlebih dahulu Basal Metabolic Rate (BMR), yaitu jumlah kalori minimum yang dibutuhkan tubuh untuk menjalankan fungsi metabolik dasar dalam kondisi istirahat total (pernapasan, sirkulasi, pemeliharaan sel, dll).

Rumus BMR berdasarkan persamaan Mifflin-St Jeor adalah:

Untuk laki-laki:

$$BMR = (10 \times BB) + (6,25 \times TB) - (5 \times U) + 5 \quad (2.9)$$

Untuk perempuan:

$$BMR = (10 \times BB) + (6,25 \times TB) - (5 \times U) - 161 \quad (2.10)$$

di mana BB adalah berat badan (kg), TB adalah tinggi badan (cm), dan U adalah usia (tahun).

Setelah BMR dihitung, kebutuhan kalori harian total (Total Daily Energy Expenditure / TDEE) diperoleh dengan mengalikan BMR dengan faktor aktivitas yang sesuai dengan tingkat aktivitas pengguna:

$$TDEE = BMR \times FaktorAktivitaas \quad (2.11)$$

Faktor aktivitas yang umum digunakan adalah:

- Sedentary (1,2): Aktivitas minimal, jarang berolahraga.
- Lightly Active (1,375): Olahraga ringan 1-3 hari per minggu.
- Moderately Active (1,55): Olahraga sedang 3-5 hari per minggu.
- Very Active (1,725): Olahraga intens 6-7 hari per minggu.
- Extremely Active (1,9): Aktivitas fisik sangat tinggi (atlet profesional).

Dalam konteks manajemen berat badan dan kebugaran, sistem ini menerapkan prinsip termodinamika dasar:

- a. Untuk penurunan berat badan (*weight loss*): defisit kalori sebesar 500 kkal/hari (TDEE - 500).
- b. Untuk penambahan otot (*muscle gain/hypertrophy*): surplus kalori sebesar 300 kkal/hari (TDEE + 300).
- c. Untuk pemeliharaan (*maintenance*): asupan kalori sesuai TDEE.

Prinsip yang digunakan adalah defisit 500 kkal/hari menghasilkan penurunan berat badan sekitar 0,5 kg per minggu (karena 1 kg lemak setara dengan 7.700 kkal), dan surplus 300 kkal/hari diterapkan untuk pertumbuhan otot karena surplus kalori yang terlalu besar akan menghasilkan penambahan lemak yang berlebihan [3].

Protein merupakan makronutrien esensial yang berperan kritis dalam proses sintesis dan pemulihan jaringan otot pasca latihan fisik. Dalam penelitian ini, kebutuhan protein harian bagi individu yang menjalani program latihan beban (*resistance training*) ditentukan berdasarkan rekomendasi ilmiah yang mengacu pada tujuan kebugaran:

- a. Untuk hipertrofi otot (*hypertrophy*): 1,8 – 2,0 gram per kilogram berat badan per hari.
- b. Untuk kekuatan (*strength*): 1,6 – 1,8 gram per kilogram berat badan per hari.
- c. Untuk penurunan berat badan dengan pertahankan otot: 2,0 – 2,2 gram per kilogram berat badan per hari.

Kebutuhan protein yang lebih tinggi pada individu aktif didasarkan pada mekanisme fisiologi bahwa latihan beban menyebabkan mikro-kerusakan serat otot, dan protein diperlukan untuk perbaikan dan pertumbuhan otot selama fase pemulihan [3]. Dalam sistem sistem, kebutuhan protein dihitung dinamis berdasarkan berat badan pengguna dan tujuan kebugaran yang dipilih, kemudian sistem merekomendasikan kombinasi menu makanan yang memenuhi target kalori dan protein spesifik tersebut.



2.2.8. Pemodelan Sistem

Pemodelan sistem digunakan untuk memvisualisasikan dan mendokumentasikan artefak dari sistem perangkat lunak. Dalam penelitian ini, digunakan dua jenis pendekatan pemodelan visual, yaitu Use Case diagram dan Activity Diagram untuk pemodelan berorientasi objek.

a. Use Case Diagram

Merupakan pemodelan untuk kelakuan (behavior) sistem informasi yang akan dibuat. Diagram ini mendeskripsikan interaksi antara satu atau lebih aktor dengan sistem, sehingga dapat diketahui fungsi-fungsi apa saja yang ada di dalam sistem tersebut [19].


Tabel 2. 2 Simbol Simbol Use Case Diagram

Simbol	Keterangan
	Aktor: Komponen yang dapat berinteraksi dengan sistem.
	Use case: Deskripsi dari urutan aksi-aksi yang ditampilkan sistem yang menghasilkan suatu hasil yang terukur bagi suatu aktor.
	Association: Komunikasi antara aktor dan use case yang berpartisipasi pada use case atau use case memiliki interaksi dengan aktor.
	Include: Relasi use case tambahan ke sebuah use case dimana use case yang ditambahkan memerlukan use case ini untuk menjalankan fungsinya atau sebagai syarat dijalankan use case.

b. Activity Diagram

Menggambarkan aliran kerja atau aktivitas dari sebuah sistem. Diagram ini memperlihatkan urutan aktivitas proses pada sistem serta membantu memahami proses secara keseluruhan [19].

Tabel 2. 3 Simbol Simbol Activity Diagram

Simbol	Keterangan
	Initial State: Menggambarkan awal dimulainya suatu aliran aktivitas.
	Final State: Menggambarkan berakhirnya dimulainya suatu aliran aktivitas
	Activity: Menggambarkan aktivitas yang dilakukan dalam suatu aliran aktivitas.
	Decision: Menggambarkan pilihan kondisi atau cabang-cabang aktifitas tertentu.
	Alur aksi: Menggambarkan transisi dari satu keadaan aksi ke keadaan aksi lainnya.

2.2.9. PostgreSQL

Integrasi PostgreSQL adalah sistem manajemen basis data relasional bersifat open-source yang mendukung penyimpanan data terstruktur, pemrosesan query yang kompleks. Dalam penelitian ini, PostgreSQL dipilih karena kemampuannya dalam mengelola data dalam jumlah besar dan dukungan penuh terhadap sistem rekomendasi berbasis data [20].

2.2.10. Streamlit

Streamlit merupakan kerangka kerja (*framework*) berbasis Python yang bersifat *open-source*, dirancang khusus untuk memfasilitasi pengembangan aplikasi web interaktif secara efisien bagi praktisi data dan pembelajaran mesin. Berbeda dengan pengembangan web konvensional yang memisahkan logika *back-end* dan antarmuka *front-end*, Streamlit memungkinkan pengembang untuk mentransformasikan skrip pemrosesan data menjadi aplikasi web fungsional tanpa memerlukan pendalaman kompleks terhadap bahasa pemrograman web seperti HTML, CSS, atau JavaScript. Kemampuan ini menjadikan Streamlit solusi yang efektif dalam mempercepat proses *prototyping* sistem, karena penyajian antarmuka pengguna dapat dilakukan secara terintegrasi menggunakan sintaks Python yang sederhana [21].

Mekanisme kerja Streamlit didasarkan pada prinsip eksekusi skrip linier dan model interaksi reaktif. Sistem menjalankan kode program secara berurutan dari atas ke bawah (*top-down*) dan secara otomatis memicu eksekusi ulang (*re-run*) pada keseluruhan skrip setiap kali mendeteksi adanya interaksi pengguna pada elemen antarmuka (*widgets*), seperti input data atau penekanan tombol. Guna menjaga stabilitas performa aplikasi di tengah proses eksekusi ulang yang intensif, Streamlit menerapkan mekanisme *caching* cerdas. Fitur ini berfungsi menyimpan hasil komputasi dari proses yang berat ke dalam memori lokal, sehingga mencegah redundansi perhitungan dan memastikan sistem tetap responsif saat menangani data dalam jumlah besar [21].

Dalam penelitian ini, Streamlit diimplementasikan sebagai antarmuka utama yang menjembatani interaksi antara pengguna dengan logika sistem rekomendasi *hybrid*. *Framework* ini bertugas menangani *input* parameter dinamis dari pengguna, meliputi data fisik untuk perhitungan BMI serta preferensi spesifik terkait menu makanan dan latihan. Data masukan tersebut diproses secara *real-time* oleh algoritma *K-Means* dan *Content-Based Filtering* yang berjalan di latar belakang, untuk kemudian hasilnya disajikan kembali kepada pengguna dalam bentuk visualisasi daftar rekomendasi yang terstruktur dan interaktif.

BAB III

METODOLOGI

3.1 Deskripsi Solusi

Penelitian proyek akhir ini mengajukan suatu pendekatan baru untuk mengatasi permasalahan rekomendasi gizi dan kebugaran yang terpersonalisasi di Max Gym Power Padang dengan mempresentasikan sistem rekomendasi *hybrid* yang memadukan tiga algoritma klasterisasi spesifik per tipe data, *Content-Based Filtering* (CBF) berbasis TF-IDF, dan *rule-based engine* untuk pengendalian logika rekomendasi. Fitur-fitur unik yang membedakan sistem ini dari pendekatan sebelumnya mencakup tiga aspek utama.

Pertama, arsitektur dua fase (*two-phase architecture*): fase *preprocessing offline* yang melatih model klasterisasi di luar sesi pengguna, dan fase operasi *online* yang hanya melakukan *assignment* profil pengguna ke klaster terdekat tanpa melatih ulang model. Pemisahan ini secara langsung mengatasi masalah *cold-start* pada kiosk baru yang belum memiliki data historis anggota, karena model K-Prototypes dilatih menggunakan *dataset* sintetis yang dibangkitkan secara *offline*, sehingga sistem dapat beroperasi sejak hari pertama tanpa bergantung pada akumulasi data nyata.

Kedua, integrasi tiga algoritma klasterisasi yang dipilih berdasarkan tipe data masing-masing entitas: K-Prototypes untuk profil anggota yang bersifat campuran (*mixed data*), K-Means untuk data nilai gizi makanan yang bersifat numerik, dan K-Modes untuk data spesifikasi latihan yang bersifat kategorikal. Kombinasi ini memastikan pengukuran jarak (*distance metric*) yang proporsional untuk setiap tipe data, menghindari bias yang timbul jika satu algoritma umum diterapkan pada semua entitas.

Ketiga, lapisan *rule-based engine* yang berfungsi sebagai pengendali logika rekomendasi di atas hasil CBF. Tanpa lapisan ini, CBF dapat menghasilkan kombinasi menu yang tidak masuk akal secara gizi (seperti merekomendasikan tiga item makanan ringan untuk makan siang) atau porsi yang tidak realistis secara fisiologis. *Rule-based engine* memastikan bahwa setiap rekomendasi mematuhi

batasan nutrisi berbasis *Total Daily Energy Expenditure* (TDEE), slot waktu makan yang terstruktur, dan batas porsi yang aman berdasarkan Pedoman Gizi Seimbang Kementerian Kesehatan RI.

3.2 Desain Sistem

Desain sistem pada penelitian ini terdiri dari dua fase utama yang terpisah secara operasional, yaitu fase *preprocessing offline* dan fase operasi *online* berbasis web.

3.2.1. Fase Preprocessing Offline

Fase *preprocessing offline* adalah seluruh proses komputasi berat yang dijalankan sebelum sistem beroperasi. Fase ini menghasilkan model yang disimpan dan digunakan kembali pada fase operasi *online* tanpa perlu diulang pada setiap sesi pengguna.

a. Pembangkitan Dataset Sintetis untuk K-Prototypes

Untuk mengatasi masalah *cold-start* pada baru yang belum memiliki data historis anggota, model K-Prototypes dilatih menggunakan dataset sintetis yang dibangkitkan secara komputasional. Dataset ini terdiri dari sekitar 5.000 profil dummy yang merepresentasikan variasi demografi kebugaran umum, dihasilkan menggunakan distribusi normal untuk atribut numerik (usia, berat badan, tinggi badan, IMT) dengan parameter statistik yang mengacu pada rentang populasi dewasa aktif Indonesia. Atribut kategorikal (jenis kelamin, tingkat aktivitas, tujuan kebugaran) dibangkitkan menggunakan distribusi proporsi yang proporsional terhadap distribusi populasi sasaran sistem (anggota gym pemula hingga menengah).

Pendekatan *dataset* sintetis ini dapat dipertahankan secara akademis karena tujuan K-Prototypes dalam sistem ini bukan untuk menganalisis karakteristik data nyata, melainkan untuk mempartisi ruang fitur fisiologis menjadi kluster-kluster yang bermakna secara domain. Saat pengguna nyata mendaftar, sistem tidak melakukan pelatihan ulang, melainkan hanya menghitung jarak profil pengguna tersebut ke seluruh centroid yang telah ada dan mengalokasikan pengguna ke kluster terdekat (*assignment-only*).

b. Klasterisasi Profil Anggota (K-Prototypes)

Dataset sintetis yang telah dibangkitkan diproses menggunakan K-Prototypes untuk menghasilkan centroid-centroid klaster. Atribut input mencakup atribut numerik (usia, berat badan, tinggi badan, IMT) dan atribut kategorikal (jenis kelamin, tingkat aktivitas, tujuan kebugaran). Centroid yang dihasilkan disimpan sebagai artefak model untuk digunakan pada fase operasi *online*. Nilai optimal k ditentukan menggunakan metode *Elbow* berbasis *Combined Cost Function* (gabungan *inertia* numerik dan *Hamming Dissimilarity Cost* kategorikal).

c. Klasterisasi Dataset Makanan (K-Means)

Dataset makanan yang digunakan adalah Dataset Menu Makanan yang memuat informasi nilai gizi dalam satuan per 100 gram bahan. Atribut yang digunakan sebagai input K-Means adalah kolom kalori (*calories*), protein (*proteins*), lemak (*fat*), dan karbohidrat (*carbohydrate*). Sebelum klasterisasi, keempat atribut dinormalisasi menggunakan MinMaxScaler agar perbedaan skala nilai (kalori dalam ratusan, protein dalam belasan) tidak mendistorsi pengukuran jarak Euclidean. Output proses ini adalah penambahan kolom `Cluster_ID` pada setiap baris dataset makanan, yang merepresentasikan keanggotaan klaster berdasarkan dominasi makronutrien (Klaster Karbohidrat, Klaster Protein, Klaster Ringan/Rendah Kalori). Nilai optimal k ditentukan secara empiris menggunakan metode *Elbow* berbasis nilai *inertia* (WSS).

d. Klasterisasi Dataset Latihan (K-Modes)

Dataset latihan yang digunakan adalah Dataset Latihan Gym yang memuat atribut kategorikal berupa *Title*, *BodyPart*, *Equipment*, dan *Type*. Karena seluruh atribut yang digunakan bersifat kategorikal, algoritma K-Modes dipilih karena kemampuannya mengukur ketidaksamaan antar data kategorikal menggunakan jarak Hamming tanpa memerlukan transformasi numerik. Dalam implementasi, parameter gamma diserahkan pada kalkulasi otomatis library `kmodes` yang menghitung nilai gamma sebagai setengah rata-rata varians kolom numerik pada *backend*-nya melalui metode inisialisasi Cao. Output proses ini adalah penambahan kolom `Cluster_ID` pada setiap

baris dataset latihan. Nilai optimal k ditentukan menggunakan metode *Elbow* berbasis *Hamming Dissimilarity Cost*.

e. Pembangunan Matriks TF-IDF

Setelah klasterisasi selesai, matriks TF-IDF dibangun secara terpisah untuk dataset makanan dan dataset latihan. Untuk dataset makanan, korpus TF-IDF dibangun dari kolom nama makanan. Untuk dataset latihan, korpus TF-IDF dibangun dari gabungan empat kolom: *Title*, *BodyPart*, *Equipment*, dan *Type*, yang digabungkan menjadi satu string teks per baris. Matriks TF-IDF yang dihasilkan disimpan bersama centroid model untuk digunakan pada fase *online*.

3.2.2. Fase Operasi Online

Fase operasi *online* adalah seluruh proses yang berjalan secara *real-time* saat anggota gym berinteraksi dengan kios. Pada fase ini, sistem hanya melakukan pemuatan artefak model yang telah dibuat pada fase *offline*, tanpa proses pelatihan ulang.

a. Alur Registrasi dan Kalkulasi Profil Fisiologis

Saat anggota baru mendaftar, sistem mengumpulkan data profil melalui formulir kios: nama, jenis kelamin, usia, berat badan (kg), tinggi badan (cm), tingkat aktivitas, dan tujuan kebugaran. Dari data ini, sistem melakukan dua kalkulasi independen secara bersamaan. Pertama, kalkulasi IMT menggunakan Persamaan (2.8) untuk keperluan klasterisasi profil. Kedua, kalkulasi TDEE menggunakan persamaan Mifflin-St Jeor (Persamaan 2.9 dan 2.10) yang kemudian dikalikan faktor aktivitas untuk mendapatkan kebutuhan kalori harian total. TDEE yang telah disesuaikan dengan tujuan kebugaran (defisit 500 kkal untuk *weight loss*, surplus 300 kkal untuk *muscle gain*, tetap untuk *maintenance*) menjadi batas filter kalori yang digunakan oleh *rule-based engine*.

b. Assignment Klaster Pengguna

Setelah profil fisiologis dihitung, sistem memuat centroid K-Prototypes dari artefak model *offline* dan menghitung jarak profil pengguna ke seluruh centroid menggunakan *Combined Cost Function* (jarak Euclidean untuk atribut numerik, jarak Hamming untuk atribut kategorikal). Pengguna

dialokasikan ke klaster dengan jarak terkecil. Proses ini bersifat *assignment-only*: centroid tidak diubah atau diperbarui. Pelatihan ulang model K-Prototypes hanya dapat dilakukan oleh admin sistem melalui *Algorithm Control Center* secara manual.

c. Pencarian Rekomendasi via CBF

Setelah klaster pengguna ditentukan, modul CBF menggunakan matriks TF-IDF yang telah dibangun pada fase *offline* untuk mencari item makanan dan latihan yang paling relevan menggunakan *cosine similarity*. Pencarian dibatasi pada item-item yang berada dalam klaster yang ditetapkan oleh *rule-based engine* sesuai slot waktu makan dan tujuan latihan, sehingga hasil CBF tidak bersifat acak tetapi terstruktur dalam kerangka template nutrisi.

3.2.3. Rule-Based Engine

Rule-based engine adalah lapisan logika deterministik yang mengatur cara kerja CBF dalam merakit rekomendasi harian. Lapisan ini terdiri dari komponen aturan yang bekerja secara berurutan.

a. Distribusi TDEE per Slot Waktu Makan

TDEE harian pengguna didistribusikan ke empat slot waktu makan menggunakan rasio tetap yang mengacu pada Pedoman Gizi Seimbang Kementerian Kesehatan RI:

Tabel 3. 1 Tabel Distribusi TDEE

Slot Waktu Makan	Proporsi TDEE	TDEE 2.000 kkal
Sarapan	25%	500 kkal
Makan Siang	35%	700 kkal
Makan Malam	30%	600 kkal
Camilan (<i>Snack</i>)	10%	200 kkal

Kuota kalori per slot ini menjadi parameter input bagi seluruh komponen *rule-based engine* berikutnya.

b. Slot-Based Meal Templating

Untuk mencegah CBF menghasilkan kombinasi menu yang tidak masuk akal secara gizi, setiap slot waktu makan diikat pada template komposisi klaster makanan yang wajib dipenuhi. Template ini memanfaatkan hasil K-Means yang membagi item makanan ke dalam tiga klaster berdasarkan dominasi makronutrien: Klaster A (dominan karbohidrat), Klaster B (dominan protein dan lemak), dan Klaster C (rendah kalori/makanan ringan). Tabel 3.2 menunjukkan template komposisi per slot.

Tabel 3. 2 Slot-Based Meal Template *per Waktu Makan*

Slot Waktu Makan	Template Klaster Wajib
Sarapan	1 item Klaster A + 1 item Klaster B
Makan Siang	1 item Klaster A + 2 item Klaster B + 1 item Klaster C
Makan Malam	1 item Klaster B + 1 item Klaster C
Cemilan	1 item Klaster C (atau Klaster A ringan)

CBF hanya diizinkan mencari item dari dalam klaster yang ditetapkan template untuk setiap posisi slot, sehingga kombinasi output selalu memenuhi struktur gizi yang logis.

c. Konversi Kalori ke Gramasi dan *Volumetric Sanity Check*

Nilai nutrisi pada dataset makanan menggunakan basis standar 100 gram. Sistem menghitung gramasi rekomendasi porsi secara dinamis menggunakan rumus berikut:

$$\text{Gramasi (g)} = \left(\frac{\text{Kuota Kalori Slot (kcal)}}{\text{Kalori per 100g dalam Dataset}} \right) \times 100 \quad (3.1)$$

Persamaan 3.1 menghasilkan porsi gramasi yang secara matematis tepat memenuhi kuota kalori slot pengguna. Hasil kalkulasi ini kemudian divalidasi melalui *Volumetric Sanity Check*: jika gramasi hasil kalkulasi berada di bawah 50 gram (tidak cukup memicu rasa kenyang) atau di atas 450 gram (melampaui batas kapasitas lambung yang nyaman untuk satu jenis item),

item tersebut didiskualifikasi dan sistem mencari item berikutnya dari hasil *ranking cosine similarity* CBF. Batas 50–450 gram mengacu pada rentang porsi standar Pedoman Gizi Seimbang Kementerian Kesehatan RI, di mana satu porsi makanan pokok berkisar sekitar 150 gram dan lauk hewani sekitar 50–100 gram.

d. *Dynamic Portion Constraint* pada Fungsi Tukar Menu (*Swap*)

Pengguna diberikan opsi untuk mengganti item makanan yang direkomendasikan dengan item lain pilihannya. Saat fungsi tukar (*swap*) diaktifkan, sistem tidak mengganti item lama dengan item baru pada gramasi *default*-nya, karena hal ini akan merusak total kalori harian yang sudah dikalkulasi berdasarkan TDEE. Sebagai gantinya, sistem menerapkan *Dynamic Portion Constraint*: item pengganti diambil dari klaster yang sama dengan item yang diganti, kemudian gramasinya dihitung ulang menggunakan Persamaan 3.1 dengan kuota kalori slot yang sama sebagai input. Dengan cara ini, total kalori harian pengguna tetap terjaga meskipun terjadi penggantian item.

e. *Safety First Filter* untuk Rekomendasi Latihan

Dataset latihan memuat atribut tingkat kesulitan (*Level*) dengan tiga nilai: *Beginner*, *Intermediate*, dan *Expert*. *Rule-based engine* menerapkan filter searah: pengguna dengan level *Beginner* hanya dapat menerima rekomendasi latihan berlabel *Beginner*; pengguna *Intermediate* dapat menerima *Beginner* dan *Intermediate*; pengguna *Expert* dapat menerima semua level. Filter ini bersifat *hard constraint* yang diterapkan setelah CBF melakukan pencarian, sehingga gerakan *Expert* tidak pernah muncul dalam rekomendasi pengguna *Beginner* meskipun skor *cosine similarity*-nya tinggi.

f. *Dynamic Parameterization*

Salah satu kelemahan sistem rekomendasi latihan yang hanya menampilkan nama gerakan adalah ketiadaan instruksi eksekusi, pengguna tidak tahu harus melakukan gerakan tersebut berapa set, berapa kali pengulangan, dan berapa lama istirahat di antara set. Tanpa informasi ini, rekomendasi tidak dapat diimplementasikan secara mandiri oleh anggota gym pemula. Untuk mengatasi ini, *rule-based engine* menerapkan *Dynamic Parameterization*,

setelah CBF menentukan gerakan yang direkomendasikan, sistem secara otomatis menginjeksi parameter dosis latihan ke dalam output berdasarkan kombinasi tujuan kebugaran dan level pengguna.

Landasan ilmiah parameter ini bersumber dari prinsip ilmu olahraga (*sports science*) yang telah divalidasi dalam penelitian-penelitian nasional. Untuk tujuan *muscle gain* (hipertrofi), latihan beban dilakukan dalam 3 set dengan repetisi 8–12 kali dan istirahat antarset 1–2 menit, karena teknik ini terbukti menambah massa otot dan membangun kekuatan secara maksimal dan optimal. Untuk tujuan *weight loss*, program *circuit weight training* yang efektif menurunkan berat badan menggunakan intensitas 50% dari 1RM dengan 15–20 repetisi serta 3–4 set per sesi latihan. Parameter-parameter ini dikunci sebagai konstanta statis dalam kode sistem dan tidak dapat diubah pengguna, karena modifikasi parameter oleh pengguna tanpa pengawasan instruktur berisiko menyebabkan cedera atau inefisiensi program.

Tabel 3. 3 Matriks *Dynamic Parameterization*

Tujuan	Beginner	Intermediate	Expert
Menurunkan berat badan	3 Set × 15 Reps, Istirahat 60s	4 Set × 15 Reps, Istirahat 60s	4 Set × 20 Reps, Istirahat 45s
Menambah berat badan	3 Set × 10 Reps, Istirahat 90s	4 Set × 10 Reps, Istirahat 90s	4 Set × 12 Reps, Istirahat 90s
Menjaga Berat Badan	3 Set × 12 Reps, Istirahat 75s	3 Set × 12 Reps, Istirahat 75s	4 Set × 12 Reps, Istirahat 75s

Tabel 3.4 menunjukkan bahwa pengguna dengan tujuan *weight loss* mendapatkan repetisi lebih tinggi (15–20) dengan istirahat lebih pendek untuk

memaksimalkan pembakaran kalori melalui stres metabolik, sementara pengguna *muscle gain* mendapatkan repetisi lebih rendah (8–12) dengan istirahat lebih panjang untuk memaksimalkan serat otot. Pendekatan ini konsisten dengan temuan bahwa volume latihan dihitung dari kombinasi jumlah set, repetisi, serta beban yang digunakan berkaitan erat dengan total stres metabolik pada otot, yang menjadi faktor utama terjadinya hipertrofi atau pembesaran sel otot.

Parameter untuk pengguna *Beginner* pada semua tujuan kebugaran sengaja dikonfigurasi lebih konservatif (set lebih sedikit, repetisi di batas bawah rentang) dibandingkan level *Intermediate* dan *Expert*. Hal ini selaras dengan prinsip keamanan latihan untuk pemula, di mana pengenalan alat dan teknik gerakan dasar dilakukan dengan beban ringan, 2–3 set per latihan, dan repetisi 12–15 kali, dengan peningkatan intensitas dilakukan secara bertahap.

g. *Cluster Diversity Enforcer*


Tanpa mekanisme pengendali keberagaman, hasil CBF berpotensi merekomendasikan seluruh gerakan latihan dari satu jenis alat yang sama misalnya seluruh rekomendasi untuk sesi *chest day* menggunakan Barbell semua karena item-item dalam klaster yang sama cenderung memiliki skor *cosine similarity* yang tinggi satu sama lain. Kondisi ini menyebabkan dua masalah praktis: pertama, pengguna harus antre di satu alat gym terus-menerus; kedua, variasi stimulus otot dari berbagai sudut mekanis tidak terpenuhi.

Untuk mengatasi ini, *rule-based engine* menerapkan *Cluster Diversity Enforcer* pada modul rekomendasi latihan. Setelah CBF menghasilkan daftar gerakan terurut berdasarkan skor *cosine similarity*, sistem menerapkan aturan bahwa setiap sesi rekomendasi wajib menyertakan gerakan dari minimal dua klaster *Equipment* yang berbeda (misalnya: 1 gerakan Barbell + 1 gerakan Dumbbell + 1 gerakan Cable atau Machine). Aturan ini diterapkan sebagai *post-processing filter* setelah pencarian CBF selesai: sistem mengambil item dengan skor tertinggi dari klaster pertama, lalu mengambil item dengan skor tertinggi dari klaster berbeda berikutnya, hingga kuota rekomendasi per sesi terpenuhi.

Landasan ilmiah penggunaan variasi alat ini didukung oleh literatur kebugaran nasional. Pendekatan optimal dalam latihan beban biasanya menggabungkan barbell untuk gerakan *compound* berat seperti *squat*, *deadlift*, dan *bench press*, serta dumbbell untuk variasi dan latihan unilateral, sehingga mendapatkan manfaat kekuatan dan stabilitas sekaligus. Selain itu, latihan dengan dumbbell membantu meningkatkan keseimbangan otot karena setiap sisi tubuh bekerja secara independen, sementara cable machine memberikan ketegangan konstan sepanjang gerakan yang efektif merangsang pertumbuhan otot. Dengan demikian, pemaksaan variasi alat oleh sistem bukan sekadar mekanisme teknis untuk menghindari antrean, tetapi memiliki justifikasi fisiologis yang valid.

3.2.4. Desain Use Case

Diagram *Diagram use case* berikut menggambarkan interaksi dua aktor sistem, yaitu Anggota Gym dan Admin, terhadap fungsionalitas utama sistem rekomendasi *hybrid*.



Gambar 3. 1 Use Case Diagram

Aktor Anggota Gym berinteraksi langsung dengan use case Hitung Kalori, yang merupakan titik masuk utama alur registrasi dan kalkulasi profil fisiologis (IMT dan TDEE) sebagaimana dijelaskan pada sub-bab Fase Operasi Online. Use case Hitung Kalori memiliki relasi *<<include>>* terhadap use case Rekomendasi

Menu dan Rekomendasi Latihan, yang berarti kedua proses rekomendasi tersebut selalu dijalankan sebagai bagian wajib setelah kalkulasi kalori selesai, sejalan dengan alur CBF dan *rule-based engine* yang telah diuraikan sebelumnya.

Aktor Admin berinteraksi dengan dua use case terpisah, yaitu Kelola Data Menu Makanan dan Kelola Data Latihan, yang memungkinkan admin melakukan operasi tambah, ubah, dan hapus terhadap data menu makanan serta data latihan gym. Kedua use case ini tidak memiliki relasi *include* atau *extend* karena bersifat independen dari alur rekomendasi anggota, namun perubahan data yang dilakukan admin dapat memicu klasterisasi ulang (K-Means atau K-Modes) yang berdampak pada hasil rekomendasi di sesi berikutnya.


3.2.5. Desain Activity Diagram

Activity Diagram menggambarkan aliran kerja atau aktivitas dari sebuah sistem, memperlihatkan urutan aktivitas proses pada sistem serta membantu memahami proses secara keseluruhan. Diagram ini memodelkan alur logika dari aktivitas yang dilakukan oleh *User* (Anggota Gym) dan respon yang diberikan oleh sistem (*System/Backend*). Berikut adalah rincian aktivitas utama dalam sistem:

a. Activity Diagram Register dan Login

Pemodelan ini menggambarkan tahapan awal pengguna dalam mengakses sistem melalui proses otentikasi. Bagi pengguna baru, alur dimulai dengan pengisian formulir pendaftaran yang memuat atribut kredensial dan demografis dasar, meliputi email, nama, tanggal lahir, jenis kelamin, serta kata sandi. Sistem kemudian bertugas memvalidasi kelengkapan dan keabsahan input tersebut sebelum merekamnya ke dalam basis data. Setelah registrasi berhasil, pengguna akan diarahkan ke antarmuka login. Pada proses login, sistem melakukan verifikasi kredensial (email dan kata sandi) yang diinputkan oleh pengguna. Apabila data dinyatakan valid, sistem akan membangkitkan sesi pengguna (*user session*) dan mengarahkan pengguna ke halaman utama untuk melanjutkan ke tahapan kalkulasi kalori; namun jika tidak valid, sistem akan menampilkan pesan galat (*error*).

Login dan Register




Gambar 3. 2 Activity Diagram Register dan Login

b. Activity Diagram Kalkulasi Kalori

Tahapan ini krusial untuk menentukan landasan rekomendasi berbasis profil fisiologis pengguna. Alur dimulai ketika anggota gym membuka menu kalkulasi profil dan memasukkan parameter tubuh terkini, yaitu berat badan, tinggi badan, tingkat aktivitas, tingkat pengalaman, dan tujuan kebugaran. Sistem akan memvalidasi integritas data tersebut sebelum melakukan komputasi matematis untuk menghitung *Basal Metabolic Rate* (BMR) dan *Total Daily Energy Expenditure* (TDEE). Setelah hasil kalkulasi metrik disimpan di dalam basis data, sistem secara otomatis memuat centroid dari model *K-Prototypes* yang telah dilatih. Anggota kemudian dialokasikan ke


dalam klaster tertentu berdasarkan proksimitas (jarak terkecil) dengan centroid tersebut. Alur ini diakhiri dengan visualisasi hasil analisis status gizi kepada anggota gym.



Gambar 3. 3 Activity Diagram Kalkulasi Kalori

c. Activity Diagram Rekomendasi Menu Makanan


Pemodelan aktivitas ini memvisualisasikan mekanisme perancangan diet personal. Setelah pengguna memasukkan preferensi makanannya, sistem mengeksekusi pencarian kandidat menu menggunakan metode *Content-Based Filtering* (CBF) yang difokuskan pada item di dalam klaster *K-Means*. Sistem kemudian membagi rekomendasi tersebut ke dalam empat proporsi waktu makan harian, yakni sarapan, makan siang, *snack* sore, dan makan malam. Lapisan validasi tambahan dilakukan untuk mengevaluasi gramasi hasil konversi kalori; apabila gramasi sebuah menu dinilai tidak logis, sistem akan mendiskualifikasi item tersebut dan mengambil kandidat menu alternatif. Menu yang telah lolos validasi gramasi akan disimpan dan ditampilkan sebagai hasil rekomendasi. Pengguna memiliki wewenang untuk menyetujui rekomendasi tersebut atau memicu fungsi penggantian menu (*swap*) apabila dirasa kurang sesuai dengan preferensi akhir.



Gambar 3. 4 Activity Diagram Rekomendasi Menu Makanan

d. Activity Diagram Kelola Menu Makanan

Alur ini mengatur logika penentuan program kebugaran fisik bagi anggota gym. Anggota menginisiasi proses dengan memilih jenis latihan dan alat yang diminati. Sistem kemudian merespons dengan mencari kandidat latihan melalui CBF pada ruang pencarian klaster *K-Modes*. Guna memitigasi risiko cedera, sistem menerapkan *Safety First Filter* yang secara ketat menyesuaikan tingkat kesulitan latihan dengan level pengalaman (kapabilitas) pengguna. Untuk memastikan keberagaman stimulus otot dan menghindari penumpukan antrean alat, sistem akan memvalidasi agar kandidat latihan diambil dari klaster *equipment* (peralatan) yang berbeda. Sebelum rekomendasi final disajikan, sistem melakukan injeksi *Dynamic Parameterization* untuk menetapkan dosis latihan secara spesifik (jumlah set, repetisi, dan durasi istirahat) sesuai tujuan kebugaran pengguna. Seperti pada modul makanan, anggota gym dapat mengevaluasi dan mengganti rancangan latihan sebelum menyimpannya ke dalam profil mereka.




Gambar 3. 5 Activity Diagram Rekomendasi Latihan

e. Activity Diagram Kelola Data Menu Makanan

Diagram aktivitas ini memodelkan proses interaksi antara administrator dan sistem dalam mengelola basis data nutrisi. Alur dimulai ketika admin mengakses menu "Kelola Data Menu Makanan" dan melakukan modifikasi data (CRUD) terhadap entri makanan. Sistem kemudian melakukan tahap validasi terhadap input yang diberikan oleh admin. Apabila input tidak valid, sistem akan menolak pembaruan dan menampilkan pesan galat. Sebaliknya, jika data valid, sistem akan menyimpan perubahan tersebut ke dalam basis data. Satu tahapan evaluasi kritis yang dilakukan oleh sistem pada fase ini adalah mendeteksi signifikansi perubahan data; apabila penambahan atau pengubahan data dinilai signifikan, sistem akan secara otomatis memicu proses klasterisasi ulang menggunakan algoritma *K-Means* pada dataset terbaru. Proses ini diikuti dengan pembaruan atribut Cluster_ID dan matriks TF-IDF untuk memastikan akurasi pencarian *Content-Based Filtering* (CBF)

pada sesi pengguna berikutnya. Alur diakhiri dengan pemberian pesan konfirmasi keberhasilan pembaruan data kepada admin.




Gambar 3. 6 Activity Diagram Kelola Data Menu Makanan

f. Activity Diagram Kelola Data Program Latihan

Secara arsitektural, diagram aktivitas pengelolaan data latihan memiliki struktur logika yang ekuivalen dengan pengelolaan menu makanan, namun berfokus pada ranah spesifikasi program kebugaran. Admin menginisiasi proses dengan memilih "Kelola Data Program Latihan" dan melakukan modifikasi data (CRUD). Setelah input melewati tahapan validasi sistem dan disimpan, sistem akan mengevaluasi apakah modifikasi tersebut memerlukan pembaruan model. Jika perubahan dianggap memengaruhi struktur data secara signifikan, sistem akan mengeksekusi klasterisasi ulang. Berbeda dengan data makanan, klasterisasi pada modul ini secara spesifik menerapkan algoritma *K-Modes* untuk menangani pemrosesan atribut yang sepenuhnya

bersifat kategorikal. Hasil dari klasterisasi ulang ini kemudian digunakan untuk memperbarui kolom identitas klaster dan matriks TF-IDF pada *backend* sistem. Siklus aktivitas ini memastikan bahwa model rekomendasi hibrida selalu beroperasi dengan representasi data (pusat klaster) yang paling mutakhir sebelum memberikan konfirmasi penyelesaian kepada admin.

Kelola Data Program Latihan



Gambar 3. 7 Activity Diagram Kelola Data Program Latihan

3.3 Rancangan Pengujian

Pengujian sistem dilakukan menggunakan metode *Black Box Testing* untuk memvalidasi kesesuaian fungsionalitas sistem dengan spesifikasi yang telah dirancang. Pengujian berfokus pada tiga aspek utama: kebenaran alur fungsional (input-proses-output), ketepatan logika *rule-based engine* dalam menghasilkan

rekomendasi yang valid secara gizi, dan ketangguhan sistem terhadap input tepi (*edge case*). Tabel 3.3 merangkum skenario pengujian yang dirancang.

Tabel 3. 4 Rencana Skenario *Black Box Testing*

No.	Skenario Uji	Input	Output yang Diharapkan
1.	Registrasi anggota baru dengan data lengkap	Data profil valid	Akun terbuat, kalkulasi IMT & TDEE berhasil, anggota dialokasikan ke klaster
2.	Registrasi dengan tinggi badan nol	TB = 0	Sistem menolak input, menampilkan pesan validasi
3.	Assignment klaster K-Prototypes	Profil anggota valid	Anggota dialokasikan ke klaster dengan <i>Combined Cost</i> terkecil
4.	Generasi rekomendasi makan siang	Klaster pengguna, TDEE, slot Makan Siang	Output: 1 item Klaster A + 2 item Klaster B + 1 item Klaster C dengan gramasi yang memenuhi 35% TDEE
5.	Fungsi <i>swap</i> menu makan siang	Pengguna mengganti Rendang dengan Ayam Goreng	Gramasi Ayam Goreng dihitung ulang sesuai kuota kalori slot Makan Siang, total kalori harian tidak berubah, <i>is_swapped</i> TRUE
6.	<i>Safety First Filter</i> pengguna <i>Beginner</i>	Level: Beginner	Rekomendasi latihan hanya menampilkan item berlabel <i>Beginner</i>
7.	<i>Safety First Filter</i> pengguna <i>Expert</i>	Level: Expert	Rekomendasi latihan menampilkan item dari semua level
8.	<i>Idempotent write</i> pada login ulang tanpa perubahan data	Data profil identik dengan log terakhir	Tidak ada baris baru yang disisipkan ke user

No.	Skenario Uji	Input	Output yang Diharapkan
9.	<i>Idempotent write</i> pada login dengan perubahan berat badan	BB berubah dari 80 ke 77 kg	Baris baru disisipkan ke user_metrics dengan nilai terbaru

BAB IV

IMPLEMENTASI DAN PENGUJIAN

4.1 Implementasi

Pada tahap implementasi proyek akhir ini, proyek dijalankan berdasarkan hasil analisis dan perancangan yang telah dilakukan sebelumnya. Setelah sistem dijalankan, dilakukan pengujian untuk memastikan bahwa hasil akhir sistem memenuhi harapan yang diinginkan.

4.1.1 Spesifikasi Perangkat

Pelaksanaan proyek akhir akan menggunakan perangkat pribadi sebagai perangkat utama dengan spesifikasi sebagai berikut:

Tabel 4. 1 Spesifikasi Perangkat Keras

Perangkat	Keterangan
Laptop	LOQ 15IRH8
Sistem Operasi	Microsoft Windows 11
Memory (RAM)	8 GB
<i>Processor</i>	12th Gen Intel(R) Core(TM) i5-12450H (2.00 GHz)
GPU	Intel(R)
<i>Storage</i>	500 GB

Adapun penggunaan perangkat lunak yang digunakan dalam pengerjaan proyek akhir ini akan dijelaskan dalam Table 4.2 berikut:

Kriteria	Teknologi
Bahasa Pemograman	Python
Framework Pemograman	Streamlit
Database	PostgreSQL
Text Editor	Visual Studio Code
Library Machine Learning	K-Means, K-Modes, K-Prototypes
Dokumentasi	Microsoft Word

4.1.2 Hasil Implementasi

4.1.3

4.2 Pengujian

4.3 Analisis Hasil Pengujian